

# Teste 3 - Planejamento de Experimento

Beatriz Lima Silveira

## Questão 1

Baixando os pacotes utilizados na questão:

```
library(rsm)
```

Criando o data.frame utilizado na questão:

```
# Criar o banco de dados
dados <- data.frame(
  x1_cod = c(-1, -1, 1, 1, 0, 0, 0, 0, 0),
  x2_cod = c(-1, 1, -1, 1, 0, 0, 0, 0, 0),
  X1 = c(80, 80, 90, 90, 85, 85, 85, 85, 85),
  X2 = c(170, 180, 170, 180, 175, 175, 175, 175, 175),
  Y = c(76.5, 77.0, 78.0, 79.5, 79.9, 80.3, 80.0, 79.7, 79.8)
)
```

Ajustando o modelo linear de primeira ordem:

```
modelo <- rsm(Y ~ F0(x1_cod, x2_cod) + TWI(x1_cod, x2_cod), data = dados)

modelo
```

Call:

```
rsm(formula = Y ~ F0(x1_cod, x2_cod) + TWI(x1_cod, x2_cod), data = dados)
```

Coefficients:

(Intercept)	F0(x1_cod, x2_cod)x1_cod	F0(x1_cod, x2_cod)x2_cod
78.97	1.00	0.50
TWI(x1_cod, x2_cod)		
0.25		

A tabela anova do modelo:

```
anova(modelo)
```

Analysis of Variance Table


Response: Y

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
F0(x1_cod, x2_cod)	2	5.00	2.500	1.150	0.3883
TWI(x1_cod, x2_cod)	1	0.25	0.250	0.115	0.7483
Residuals	5	10.87	2.174		


A análise da ANOVA sugere que nem os termos lineares nem os de interação são estatisticamente significativos, pois os p valores são altos.

Costrução do gráfico:

```
contour(modelo, ~x1_cod + x2_cod,  
        image = TRUE,  
        xlab = c("x1 (Tempo)", "x2 (Temperatura)"))
```



```
persp(modelo, ~ x1_cod + x2_cod,
      theta = 30, phi = 20,
      expand = 0.6,
      col = terrain.colors(50), contours = "colors",
      zlab = "Aumento de peso", xlab = c("x1 (Tempo)", "x2 (Temperatura)"))
```



## Questão 2

Baixando os pacotes utilizados na questão:

```
library(dplyr)
library(tidyr)
library(ggplot2)
library(lme4)
library(car)
library(lmtest)
```

Criando o data.frame utilizado na questão:

```
# Criar o banco de dados
dados <- data.frame(
  racao = rep(c("C0", "C1"), each = 12),
  ambiente = rep(c("L0", "L0", "L0", "L0", "L0", "L0",
    "L1", "L1", "L1", "L1", "L1", "L1"), times = 2),
  repeticao = rep(c(1,2,3,4,5,6), each = 4),
  ovos = c(60 , 62 , 58 , 64 , 62 , 60,
    49 , 52 , 50 , 48 , 46 , 45,
    42 , 44 , 46 , 43 , 44 , 45,
    40, 40 , 38 , 39 , 41 , 43)
)

# converter variáveis categóricas para fatores
dados <- dados %>%
  mutate(racao = factor(racao),
    ambiente = factor(ambiente))

summary(dados)
```

racao	ambiente	repeticao	ovos
C0:12	L0:12	Min. :1.0	Min. :38.00
C1:12	L1:12	1st Qu.:2.0	1st Qu.:42.75
		Median :3.5	Median :45.50
		Mean :3.5	Mean :48.38
		3rd Qu.:5.0	3rd Qu.:53.50
		Max. :6.0	Max. :64.00

```
modelo <- aov(ovos ~ racao * ambiente,
  data = dados)

summary(modelo)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
racao	1	950.0	950.0	237.0	1.49e-12 ***
ambiente	1	408.4	408.4	101.9	2.70e-09 ***
racao:ambiente	1	117.0	117.0	29.2	2.74e-05 ***
Residuals	20	80.2	4.0		

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

```
anova(modelo)
```

### Analysis of Variance Table

Response: ovos

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
racao	1	950.04	950.04	237.02	1.488e-12 ***
ambiente	1	408.38	408.38	101.88	2.704e-09 ***
racao:ambiente	1	117.04	117.04	29.20	2.737e-05 ***
Residuals	20	80.17	4.01		

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

De acordo com a anova, a ração ter calcio ou não ter influência a produção de ovos, bem como a luz do ambiente, diferentes combinações dessas variáveis também influenciam a produção.

Testando pressupostos:

```
# 1. normalidade
```

```
shapiro.test(resid(modelo)) # é normal
```

Shapiro-Wilk normality test

data: resid(modelo)

W = 0.9793, p-value = 0.8827

```
# 2. homocedasticidade
```

```
leveneTest(modelo) # é homogeneo
```

Levene's Test for Homogeneity of Variance (center = median)

	Df	F value	Pr(>F)
group	3	0.9848	0.4198
	20		


```
# 3. independencia dos erros

dwtest(modelo) # não parece ser dependente
```


Durbin-Watson test

```
data: modelo
DW = 1.5457, p-value = 0.03265
alternative hypothesis: true autocorrelation is greater than 0
```

```
# Plot de Resíduos vs. Valores Ajustados
plot(modelo, which = 1)
```



```
# Gráfico de resíduos vs. ordem das observações
plot(residuals(modelo), type = "o", main = "Resíduos vs Ordem")
```



Os resíduos seguem uma distribuição normal, o que valida a suposição da ANOVA. As variâncias dos grupos são homogêneas, o que valida mais uma suposição da ANOVA. Considerando o teste durbin watson, há uma indicação de correlação positiva entre os resíduos. O gráfico sugere que não há grandes padrões nos resíduos, o que é um bom sinal para a ANOVA.

Teste de comparações múltiplas:

```
# Realizando o teste de Tukey
tukey_resultado <- TukeyHSD(modelo)

# Visualizando os resultados do teste de Tukey
tukey_resultado
```

```
Tukey multiple comparisons of means
95% family-wise confidence level
```

```
Fit: aov(formula = ovos ~ racao * ambiente, data = dados)
```

```
$racao
      diff      lwr      upr p adj
C1-C0 -12.58333 -14.28829 -10.87838    0
```

```
$ambiente
```


	diff	lwr	upr	p adj
L1-L0	-8.25	-9.954955	-6.545045	0

```
$`raca:ambiente`
```

	diff	lwr	upr	p adj
C1:L0-C0:L0	-17.000000	-20.235298	-13.7647021	0.0000000
C0:L1-C0:L0	-12.666667	-15.901965	-9.4313687	0.0000000
C1:L1-C0:L0	-20.833333	-24.068631	-17.5980354	0.0000000
C0:L1-C1:L0	4.333333	1.098035	7.5686313	0.0063812
C1:L1-C1:L0	-3.833333	-7.068631	-0.5980354	0.0166856
C1:L1-C0:L1	-8.166667	-11.401965	-4.9313687	0.0000042

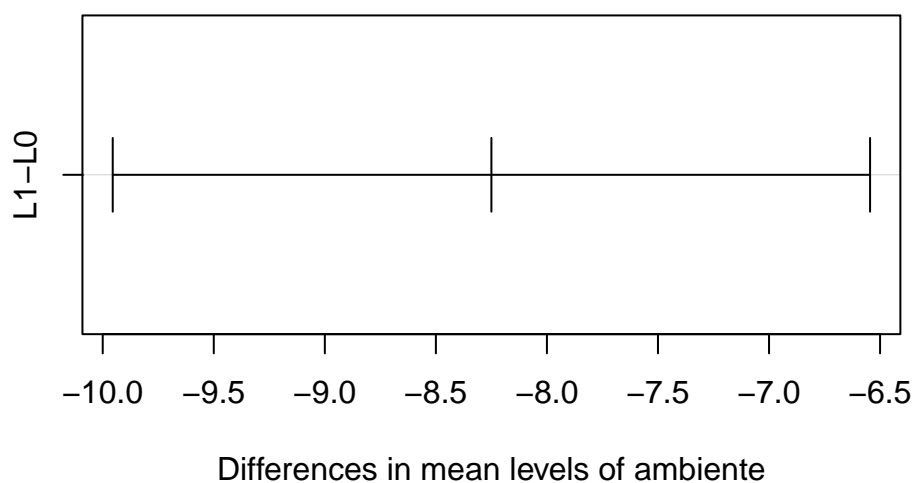
```
# Plotando os resultados do teste de Tukey  
plot(tukey_resultado)
```

### 95% family-wise confidence level

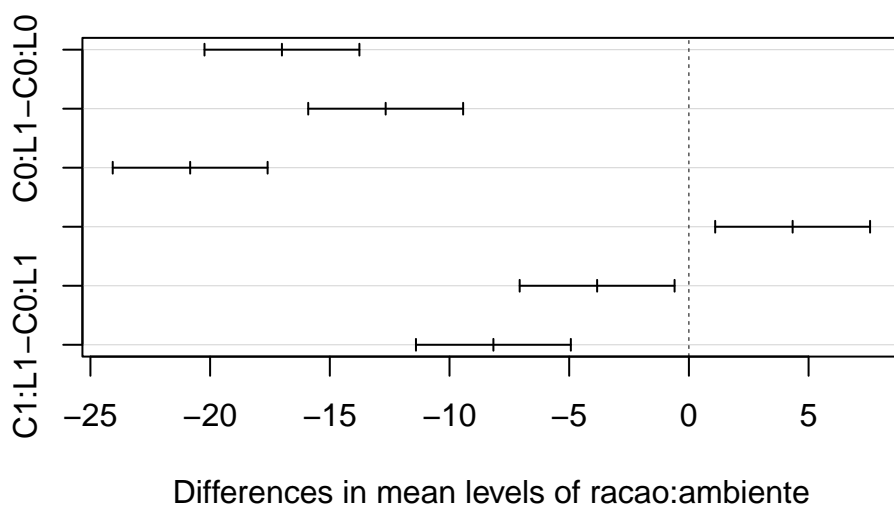




### 95% family-wise confidence level



### 95% family-wise confidence level



O menor número de ovos ocorre quando usamos a ração C1 no ambiente L1. A maior produção ocorre com a ração C0 no ambiente L0. A diferença entre C0 e C1 é maior no ambiente L1,

indicando uma interação importante.